

Tunowalność wybranych algorytmów uczenia maszynowego

Szymon Kiełyka, Ryszard Czarnecki, Antoni Rakowski

18 listopada 2025

1 Algorytmy i zbiory danych

Wybrane algorytmy: DecisionTreeClassifier, KNeighborsClassifier, LogisticRegression z penalty='elasticnet' Wybrane zbiory danych: Credit, Blood, Jm1, Bank marketing, Diabetes, Heart, Pc4, Sonar, Schizo, Cmc, Eucalyptus

2 Wykorzystane metody

2.1 Zakresy hiperparametrów

Zakresy hiperparametrów zostały wybrane na podstawie dokumentacji oraz artykułu (Probs et al., 2019)

Algorytm	Hiperparametr	Zakres
DecisionTreeClassifier	max_depth min_samples_split min_samples_leaf	[1, 30] [1, 60] [1, 60]
KNeighborsClassifier	n_neighbors weights	[1, 30] {'uniform', 'distance'}
LogisticRegression z penalty='elasticnet'	C l1_ratio	[$2^{-10}, 2^{10}$] [0, 1]

Tabela 1: Zakresy hiperparametrów dla wybranych algorytmów.

2.2 Metody wyboru punktów

Do wyboru punktów zostały użyte dwie metody: RandomizedSearchCV z pakietu scikit-learn oraz BayesSearchCV z pakietu scikit-optimize. Dla modeli DecisionTreeClassifier oraz LogisticRegression zrobiono 100 iteracji każdej z metod losowania punktów, a dla modelu KNeighborsClassifier 50 iteracji. W metodzie RandomizedSearchCV dla każdego zbioru danych przeszukiwana była taka sama siatka punktów dla danego modelu.

2.3 Definicje

Definicje optymalnej konfiguracji hiperparametrów dla danego zbioru, domyślnej konfiguracji hiperparametrów oraz tunowalności algorytmów zostały wyznaczona zgodnie z definicjami z artykułu (Probs et al., 2019). Jako funkcje straty R urzyto metryki AUC.

Definicja domyślnej konfiguracji hiperparametrów:

$$\theta^* := \arg \min_{\theta \in \Theta} g(R^{(1)}(\theta), \dots, R^{(m)}(\theta)),$$

gdzie g - funkcja agregująca (wykorzystana została średnia)

Definicja optymalnej konfiguracji hiperparametrów dla j -ego zbioru:

$$\theta^{(j)*} := \arg \min_{\theta \in \Theta} R^{(j)}(\theta).$$


Definicja tunowalności algorytmu dla j-tego zbioru danych:

$$d^{(j)} := R^{(j)}(\theta^*) - R^{(j)}(\theta^{(j)*})$$

Ogólna tunowalność algorytmu została wyznaczona przez średnią tunowalność algorytmu dla wszystkich zbiorów danych.

3 Wyniki eksperymentów

3.1 Stabilne wyniki optymalizacji



Rysunek 1: Średnia liczba iteracji do osiągnięcia stabilnego wyniku (99,9% najlepszego wyniku)

Aby osiągnąć stabilne wyniki optymalizacji metoda BayesSearchCV potrzebuje średnio nieznacznie mniej kroków niż RandomizedSearchCV, aczkolwiek może się to różnić przy danym modelu


3.2 Domyślne konfiguracje

Algorytm	Hiperparametr	Wartość
DecisionTreeClassifier	max_depth	7
	min_samples_split	9
	min_samples_leaf	10
KNeighborsClassifier	n_neighbors	22
	weights	distance
LogisticRegression z penalty='elasticnet'	C	0.0802
	l1_ratio	0.1101

Tabela 2: Najlepsze znalezione wartości hiperparametrów dla każdego klasyfikatora

Domyślne konfiguracje dla danego modelu uzyskano przez wybór najlepszego średniego wyniku AUC dla wszystkich zbiorów danych

3.3 Tunowalność




Rysunek 2: Tunowalność danych modeli

Obie techniki samplingu uzyskały lepsze wyniki niż domyślne wartości parametrów. Najbardziej tunowalnym algorytmem jest DecisionTreeClassifier (średnia tunowalność 0.03740), następnie KNeighborsClassifier (średnia tunowalność 0.021446), a najmniej tunowalnym algorytmem jest LogisticRegression z penalty='elasticnet' (średnia tunowalność 0.00388)

Zbiór danych	LogisticRegression		DecisionTreeClassifier		KNeighborsClassifier		
	Random Search	Bayes Opt	Random Search	Bayes Opt	Random Search	Bayes Opt	
bank marketing	credit	0.0005	0.0007	0.0176	0.0177	0.0014	0.0014
	jm1	0.0038	0.0038	0.0320	0.0323	0.0027	0.0027
	blood	0.0000	0.0005	0.0471	0.0471	0.0325	0.0326
	diabetes	0.0004	0.0004	0.0401	0.0404	0.0064	0.0064
	heart	0.0044	0.0046	0.0493	0.0493	0.0031	0.0031
	pc4	0.0028	0.0050	0.0654	0.0425	0.0033	0.0047
	sonar	0.0085	0.0086	0.0527	0.0527	0.0047	0.0047
	schizo	0.0003	0.0020	0.0521	0.0682	0.0613	0.0613
	cmc	0.0108	0.0187	0.0237	0.0296	0.0945	0.0945
	eucalyptus	0.0015	0.0016	0.0298	0.0318	0.0233	0.0251

Tabela 3: Tunowalność dla modelu i metody wyboru punktów

3.4 Bias sampling



Rysunek 3: Średnia tunowalność dla danej metody samplingu

Wyniki dla Random Search i Bayesian Optimization są bardzo zbliżone, więc nie można stwierdzić, że występuje bias sampling.

4 Literatura

- [1] Probst, P., Boulesteix, A.-L., Bischl, B. (2019). Tunability: Importance of Hyperparameters of Machine Learning Algorithms. *Journal of Machine Learning Research*, 20, 1-32. Dostęp online: <https://jmlr.org/papers/volume20/18-444/18-444.pdf>